Modelos de Regressão e Aprendizado Supervisionado II

Atividade para casa: modelagem do absenteísmo escolar

---

1. Objetivos

Esta atividade tem como objetivo consolidar a análise de dados de contagem por meio de modelos lineares generalizados. Ao final, espera-se que o grupo seja capaz de:

- reconhecer a natureza discreta e não negativa de uma resposta de contagem;
- formular e interpretar um modelo de regressão de Poisson com ligação logarítmica;
- avaliar equidispersão, sobredispersão e possível excesso de zeros;
- comparar Poisson, quase-Poisson e binomial negativo;
- selecionar uma estrutura sistemática respeitando o princípio da hierarquia;
- realizar análise residual e diagnóstico de influência;
- avaliar desempenho preditivo por validação cruzada;
- elaborar uma conclusão integrada e reconhecer limitações da análise.

2. Contexto e descrição dos dados

Serão utilizados os dados `quine`, disponíveis no pacote `MASS`. A base contém 146 estudantes de escolas rurais de Walgett, no estado de Nova Gales do Sul, Austrália. Para cada estudante, registrou-se o número de dias de ausência em determinado ano escolar, juntamente com características demográficas e educacionais.

`Variável`	Descrição	Tipo
`Days`	Número de dias de ausência no ano escolar	Contagem
`Eth`	Origem étnica: aborígene (A) ou não aborígene (N)	Qualitativa
`Sex`	Sexo: feminino (F) ou masculino (M)	Qualitativa
`Age`	Grupo escolar: F0, F1, F2 ou F3	Qualitativa ordinal
`Lrn`	Situação de aprendizagem: média (AL) ou lenta (SL)	Qualitativa

Considere

$$Y_i = \texttt{Days}_i, \qquad Y_i \in \{0, 1, 2, \ldots\},$$

e denote por

$$\mu_i = \mathrm{E}(Y_i \mid \boldsymbol{x}_i)$$

o número médio de dias de ausência para estudantes com características $\boldsymbol{x}_i$.

Os dados provêm de uma classificação observacional e desbalanceada. Portanto, diferenças entre grupos não devem ser automaticamente interpretadas como efeitos causais.

3. Orientações para a entrega

- A atividade poderá ser realizada em grupos de até _____ estudantes.
- Entregar um relatório em PDF com, no máximo, 12 páginas, excluindo apêndices.
- O relatório deverá conter tabelas e figuras legíveis, numeradas e discutidas no texto.
- Não serão aceitas saídas computacionais extensas sem edição ou interpretação.
- Toda escolha de modelo, categoria de referência, interação ou procedimento de diagnóstico deverá ser justificada.
- O material computacional deverá ser entregue separadamente para fins de reprodutibilidade, mas não deve ocupar o corpo principal do relatório.
- Esta atividade solicita uma análise estatística, e não apenas a identificação do menor AIC ou do menor erro preditivo.

4. Parte A — compreensão e preparação dos dados [10 pontos]

A1. Defina a unidade observacional, a população estudada, a resposta e as covariáveis. Explique por que `Days` é uma contagem e por que um modelo Normal pode ser inadequado. [2 pontos]

A2. Verifique valores ausentes, categorias vazias e a distribuição do número de estudantes entre as combinações de `Eth`, `Sex`, `Age` e `Lrn`. Discuta as consequências do desbalanceamento. [3 pontos]

A3. Informe as categorias de referência adotadas. Explique como essa escolha afeta a interpretação dos coeficientes, mas não os valores ajustados nem as comparações globais. [2 pontos]

A4. A variável `Age` representa grupos escolares, não a idade numérica do estudante. Discuta duas formas de incorporá-la ao modelo: como fator nominal e como fator ordinal. Indique qual será usada na análise principal. [3 pontos]

5. Parte B — análise exploratória [15 pontos]

B1. Apresente mínimo, quartis, média, mediana, máximo, variância e desvio-padrão de `Days`. Compare média e variância e antecipe possíveis consequências para um modelo de Poisson. [3 pontos]

B2. Apresente a distribuição de frequências de `Days` por meio de uma tabela e de um gráfico apropriado. Descreva assimetria, concentração, cauda direita e observações extremas. [3 pontos]

B3. Calcule a proporção observada de zeros

$$\widehat{p}_0 = \frac{1}{n}\sum_{i=1}^{n} I(Y_i = 0).$$

Explique por que a presença de alguns zeros não implica, por si só, inflação de zeros. [3 pontos]

B4. Compare a distribuição das ausências entre os níveis de `Eth`, `Sex`, `Age` e `Lrn`. Para cada variável, apresente tamanho do grupo, média, mediana, variância e uma representação gráfica. [4 pontos]

B5. Formule duas hipóteses substantivas que possam ser investigadas por interações entre as covariáveis. As hipóteses devem ser declaradas antes do ajuste das interações. [2 pontos]

6. Parte C — formulação dos modelos de contagem [15 pontos]

C1. Formule o modelo de Poisson:

$$Y_i \mid \boldsymbol{x}_i \sim \text{Poisson}(\mu_i), \qquad P(Y_i = y_i \mid \boldsymbol{x}_i) = \frac{e^{-\mu_i}\mu_i^{y_i}}{y_i!}.$$

Identifique seu suporte, média e variância condicionais. Explique a hipótese de equidispersão. [3 pontos]

C2. Considere a ligação logarítmica

$$\log(\mu_i) = \eta_i = \boldsymbol{x}_i^\top \boldsymbol{\beta}.$$

Mostre que

$$\mu_i = \exp(\boldsymbol{x}_i^\top \boldsymbol{\beta}) > 0$$

e explique por que essa ligação é conveniente para uma média de contagem. [2 pontos]

C3. Para uma covariável dicotômica x_j, mostre que $\exp(\beta_j)$ é uma razão de médias, mantidas as demais covariáveis constantes. Interprete também

$$100\{\exp(\beta_j) - 1\}\%.$$

[3 pontos]

C4. Apresente as formulações média–variância dos modelos:

$$\begin{aligned} \text{Poisson:} &\qquad \text{Var}(Y_i \mid \boldsymbol{x}_i) = \mu_i, \\ \text{quase-Poisson:} &\qquad \text{Var}(Y_i \mid \boldsymbol{x}_i) = \phi\mu_i, \\ \text{binomial negativo:} &\qquad \text{Var}(Y_i \mid \boldsymbol{x}_i) = \mu_i + \alpha\mu_i^2. \end{aligned}$$

Compare o papel de ϕ e α. [4 pontos]

C5. Explique por que o quase-Poisson não especifica uma distribuição completa e, consequentemente, o AIC usual não é definido a partir de uma verossimilhança quase-Poisson. [3 pontos]

7. Parte D — estrutura sistemática e inferência [20 pontos]

Considere como ponto de partida os modelos:

$$\begin{aligned} M_0 &: \quad \eta_i = \beta_0, \\ M_1 &: \quad \eta_i = \beta_0 + \texttt{Eth}_i + \texttt{Sex}_i + \texttt{Age}_i + \texttt{Lrn}_i, \\ M_2 &: \quad M_1 + \texttt{Eth}_i\texttt{:Sex}_i, \\ M_3 &: \quad M_1 + \texttt{Age}_i\texttt{:Lrn}_i, \\ M_4 &: \quad M_1 + \texttt{Eth}_i\texttt{:Age}_i + \texttt{Age}_i\texttt{:Lrn}_i. \end{aligned}$$

D1. Ajuste inicialmente M_1 sob a hipótese Poisson. Apresente uma tabela com estimativas, erros-padrão, intervalos de confiança de 95%, razões de médias e respectivos intervalos. [4 pontos]

D2. Interprete substantivamente pelo menos três contrastes, incluindo um para `Eth`, um para `Lrn` e um entre dois níveis de `Age`. Evite interpretar cada coeficiente apenas como "aumento" ou "redução" sem indicar o grupo de referência. [4 pontos]

D3. Avalie globalmente a contribuição de cada fator. Explique por que um fator com vários níveis pode ser relevante mesmo quando alguns coeficientes individuais não são significativos. [3 pontos]

D4. Compare M_1–M_4 respeitando o princípio da hierarquia: uma interação somente poderá permanecer se os efeitos principais correspondentes forem mantidos. Utilize critérios adequados e considere a motivação substantiva das interações. [4 pontos]

D5. Para o modelo selecionado, estime o número médio de dias de ausência para pelo menos quatro perfis de estudantes. Apresente estimativas pontuais e intervalos de confiança e compare os perfis por razões de médias. [3 pontos]

D6. Explique por que as associações estimadas não devem ser interpretadas como efeitos causais de origem étnica, sexo ou situação de aprendizagem. [2 pontos]

8. Parte E — dispersão e escolha da distribuição [15 pontos]

E1. Para o modelo Poisson selecionado, calcule a dispersão de Pearson

$$\widehat{\phi}_P = \frac{1}{n-p}\sum_{i=1}^{n}\frac{(y_i-\widehat{\mu}_i)^2}{\widehat{\mu}_i}.$$

Interprete valores próximos de 1, superiores a 1 e inferiores a 1. [3 pontos]

E2. Examine também a razão entre o desvio residual e os graus de liberdade. Explique por que nenhuma dessas razões deve ser tratada isoladamente como prova definitiva de adequação ou inadequação. [2 pontos]

E3. Compare a proporção observada de zeros, $\widehat{p}_0$, com a proporção média prevista pelo Poisson:

$$\widehat{p}_{0,P} = \frac{1}{n}\sum_{i=1}^{n} e^{-\widehat{\mu}_i}.$$

Conclua se há evidência descritiva de excesso ou déficit de zeros. [3 pontos]

E4. Ajuste o mesmo preditor pelos modelos quase-Poisson e binomial negativo. Compare estimativas, erros-padrão, intervalos e conclusões inferenciais. Explique por que o quase-Poisson altera principalmente a incerteza, enquanto o binomial negativo pode também alterar as estimativas. [4 pontos]

E5. Compare Poisson e binomial negativo por AIC e BIC. Para o quase-Poisson, utilize diagnóstico de dispersão, inferência e desempenho preditivo, sem apresentar AIC usual. Indique a família provisoriamente preferida. [3 pontos]

9. Parte F — resíduos e influência [15 pontos]

F1. Para Poisson e binomial negativo, examine resíduos de Pearson e de desvio padronizados. Apresente resíduos versus valores ajustados, resíduos versus índice e gráficos separados pelos principais fatores. [4 pontos]

F2. Construa um gráfico quantil–quantil com envelope simulado para pelo menos o modelo final. Explique por que o envelope é mais informativo que comparar diretamente resíduos discretos com uma reta normal teórica. [3 pontos]

F3. Utilize conjuntamente resíduos, alavancagem e distância de Cook para identificar observações potencialmente problemáticas. Diferencie:

- ponto discrepante;
- ponto de alta alavancagem;
- ponto influente.

[3 pontos]

F4. Selecione até cinco estudantes para investigação detalhada. Apresente resposta, covariáveis, valor ajustado, resíduo, alavancagem e distância de Cook. Explique por que uma grande contagem não é automaticamente um erro. [2 pontos]

F5. Realize análise de sensibilidade com e sem os casos mais influentes. Compare parâmetros, razões de médias, incerteza e conclusões. Não elimine casos da análise principal sem justificativa substantiva ou evidência de erro. [3 pontos]

10. Parte G — validação cruzada e conclusão [10 pontos]

Utilize validação cruzada estratificada com dez grupos e as mesmas partições para todos os modelos. Sempre que houver seleção de estrutura, ela deverá ser repetida dentro de cada amostra de treinamento.

G1. Descreva a construção dos grupos e verifique se as categorias de `Eth`, `Sex`, `Age` e `Lrn` permanecem representadas nos conjuntos de treinamento. [2 pontos]

G2. Para cada modelo, calcule a perda média de Poisson fora da amostra

$$\mathrm{Dev}_{CV} = \frac{1}{n}\sum_{i=1}^{n} d\{y_i, \widehat{\mu}_i^{(-v_i)}\},$$

além de MAE_{CV} e RMSE_{CV}. Justifique por que a correlação observada–previsto não deve ser utilizada como critério principal. [3 pontos]

G3. Compare a ordenação dos modelos por validação cruzada com aquela obtida pelos critérios de informação e pelo diagnóstico de dispersão. Discuta diferenças pequenas em termos práticos, sem declarar automaticamente um vencedor. [2 pontos]

G4. Redija uma conclusão de até 500 palavras respondendo:

> Qual combinação entre estrutura sistemática e distribuição apresenta o melhor equilíbrio entre interpretação, adequação, estabilidade e capacidade preditiva?

Reconheça limitações do estudo e evite conclusões causais. [3 pontos]

11. Critérios de avaliação

Componente	Pontuação
Compreensão e preparação dos dados	10
Análise exploratória	15
Formulação dos modelos de contagem	15
Estrutura sistemática e inferência	20
Dispersão e escolha da distribuição	15
Resíduos e influência	15
Validação cruzada e conclusão	10
Total	100

Também serão avaliados clareza da escrita, legibilidade das figuras, coerência entre objetivos e métodos, interpretação na escala original, respeito ao princípio da hierarquia e reprodutibilidade.

12. Referências recomendadas

- CAMERON, A. C.; TRIVEDI, P. K. *Regression Analysis of Count Data*. 2. ed. Cambridge: Cambridge University Press, 2013.
- COOK, R. D.; WEISBERG, S. *Residuals and Influence in Regression*. New York: Chapman and Hall, 1982.
- HILBE, J. M. *Negative Binomial Regression*. 2. ed. Cambridge: Cambridge University Press, 2011.
- McCULLAGH, P.; NELDER, J. A. *Generalized Linear Models*. 2. ed. London: Chapman and Hall, 1989.
- VENABLES, W. N.; RIPLEY, B. D. *Modern Applied Statistics with S*. 4. ed. New York: Springer, 2002.
- AITKIN, M. The analysis of unbalanced cross-classifications. *Journal of the Royal Statistical Society: Series A*, v. 141, p. 195–223, 1978.