Modelagem do Absenteísmo Escolar com Modelos de Regressão para Dados de Contagem

Davi Ferrari Hannickel - 15447480
Henrique Nardi Farbelow - 15459250

SME0823 - Modelos de Regressão e Aprendizado Supervisionado II
Outubro de 2026

Introdução e Contextualização

O objetivo deste trabalho é modelar o número de dias de ausência escolar por meio de modelos lineares generalizados para dados de contagem, percorrendo as etapas de preparação dos dados, análise exploratória, formulação, ajuste, inferência e seleção da estrutura sistemática. Os dados são os da base quine, do pacote MASS, e as análises foram conduzidas em Python (statsmodels), encontradas no repositório:

https://github.com/hnfarbelow/GLM_Contagem

Parte A — Compreensão e Preparação dos Dados

A1. Unidade observacional e variáveis

A unidade observacional é o estudante, e a população de interesse é composta por estudantes de escolas rurais de *Walgett*, Nova Gales do Sul, na Austrália. A base contém $n = 146$ observações. As variáveis são:

- Variável resposta (Y_i): Days_i (número de dias de ausência no ano escolar).
- Covariável `Eth` (Origem étnica): A (aborígene) ou N (não aborígene).
- Covariável `Sex` (Sexo): F ou M.
- Covariável `Age` (Grupo escolar): $F0$, $F1$, $F2$ ou $F3$.
- Covariável `Lrn` (Situação de aprendizagem): AL (média) ou SL (lenta).

`Days` é uma variável de contagem, discreta e não negativa. O modelo de regressão Normal assume suporte em $(-\infty, +\infty)$, simetria e variância constante. Entretanto, para contagens, a distribuição costuma ser assimétrica à direita e com variância dependente da média, o que torna a distribuição Normal inadequada, podendo até mesmo gerar previsões negativas que não tem sentido.

A2. Dados ausentes e desbalanceamento

Não foram encontrados valores ausentes. A combinação ($\texttt{Age} = F3, \quad \texttt{Lrn} = SL$) é a única que não existe na base. O desbalanceamento do número de observações em algumas combinações de categorias aumenta a variabilidade do modelo em grupos menores e pode indicar correlação entre certas variáveis.

A3. Categorias de referência

Adotamos como referência Eth = N, Sex = $F1$, Age = $F1$ e Lrn = AL, por serem as categorias mais frequente em suas respectivas variáveis. Essa escolha define a interpretação do intercepto β_0. A mudança de referência altera a parametrização e a variabilidade individual, mas mantém os valores ajustados $\hat{\mu}_i$, os testes globais e os critérios de seleção.

A4. Tratamento da variável `Age`

A variável `Age` representa grupos escolares, e não a idade numérica em si. Ela entra no modelo como três variáveis *dummy* ($F0$, $F2$, $F3$ contra $F1$). Por representarem valores numéricos, existe a ordenação $F0 < F1 < F2 < F3$, ou seja, é possível transformar as categorais em valores numéricos, como por exemplo a idade mediana de cada categoria. Entretanto, existe uma perda de informação ao fazer essa transformação, pois os dados podem ser assimétricos dentro de cada categoria, então utilizaremos a própria categorização na análise (fator nominal).

Parte B - Análise Exploratória

B1. Medidas descritivas

A Tabela 1 resume a distribuição de `Days`. A média amostral é cerca de 16 vezes inferior à variância. Como o modelo de Poisson pressupõe uma equidispersão, esse resultado indica que o modelo irá subestimar os erros-padrões. Vale destacar que a média é, na realidade, muito próxima do desvio-padrão, indicando que possa haver uma relação quadrática entre média e variância,

Tabela 1: Estatísticas descritivas de `Days` ($n = 146$).

Mínimo	Q_1	Mediana	Média	Q_3	Máximo	Variância	Desvio-padrão
0	5,00	11,00	16,46	22,75	81	264,17	16,25

B2. Distribuição de frequências

A Figura 1 mostra o histograma e o boxplot de `Days`. A distribuição apresenta uma forte assimetria à direita (como discutido anteriormente), com concentração dos estudantes em valores baixos e uma cauda longa que se estende até 81 dias. o Boxplot indica a presença de 7 observações extremas (*outliers*).

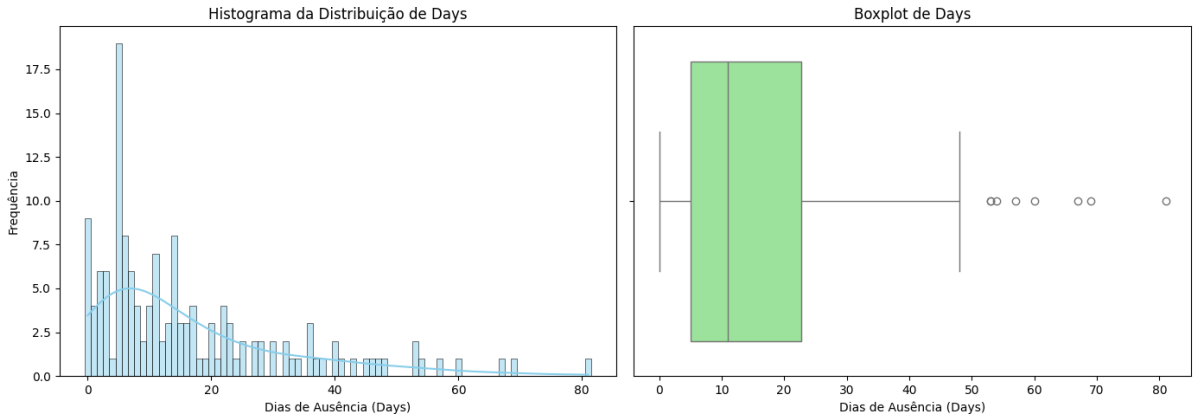


Figura 1: Histograma e boxplot da variável `Days`.

B3. Proporção de zeros

A proporção observada de zeros é $\hat{p}_0 = 9/146 \approx 6{,}16\%$. A presença de zeros não implica em uma inflação, pois em modelos de contagem o zero faz parte do suporte natural. Só há evidência de inflação caso o modelo ajustado subestime estruturalmente a proporção de zeros, o que será avaliado após o ajuste.

B4. Comparação entre grupos

A Tabela 2 apresenta o tamanho, a média, a mediana e a variância de `Days` por nível de cada covariável, e a Figura 2 exibe os boxplots correspondentes. Interpretamos:

- Etnia: Estudantes aborígenes apresentam uma média de ausências superior em comparação aos não aborígenes.
- Idade: O grupo $F1$ registra a menor média e os grupos $F2$ e $F3$ concentram as maiores médias.
- Sexo: As diferenças nas médias de ausências entre os sexos são baixas.
- Situação de Aprendizagem: As variações entre as médias de aprendizagem também são sutis, entretanto a variância do grupo SL é nitidamente maior que no grupo AL.

Em todos os grupos a variância excede muito a média, o que reforça a sobredispersão.

Tabela 2: Estatísticas de `Days` por nível das covariáveis.

Variável	Nível	n	Média	Mediana	Variância
`Eth`	N	77	12,18	7,0	183,89
	A	69	21,23	15,0	313,95
`Sex`	F	80	15,23	10,0	253,80
	M	66	17,95	14,0	276,69
`Age`	$F0$	27	14,85	11,0	218,90
	$F1$	46	11,15	6,0	135,51
	$F2$	40	21,05	14,0	405,48
	$F3$	33	19,61	18,0	255,18
`Lrn`	AL	83	15,82	12,0	193,49
	SL	63	17,30	10,0	360,63

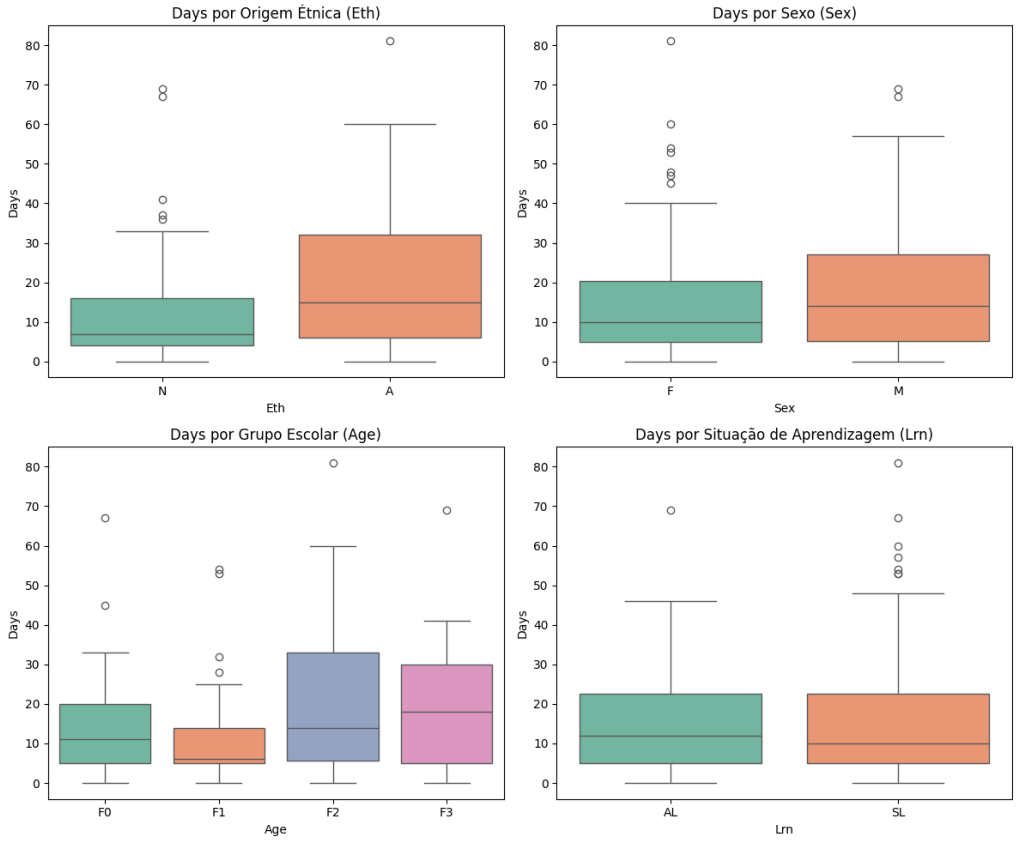


Figura 2: Boxplots de `Days` por `Eth`, `Sex`, `Age` e `Lrn`.

B5. Hipóteses substantivas de interação

Destacamos duas hipóteses com base na análise exploratória:

1. Eth × Sex**:** o efeito do sexo é diferentes entre as origem étnica, pois existem fatores culturais associados ao gênero que podem diferir entre aborígenes e não aborígenes.

2. Age × Lrn**:** o impacto de uma aprendizagem lenta (SL) muda ao longo dos grupos etários, pois é plausível a existência de um efeito cumulativo ao longo da fase escolar.

Parte C - Formulação dos Modelos de Contagem

C1. Modelo de Poisson

Definimos $Y_i \mid x_i \sim \text{Poisson}(\mu_i)$:

$$P(Y_i = y_i \mid x_i) = \frac{e^{-\mu_i}\mu_i^{y_i}}{y_i!}, \qquad y_i \in \{0, 1, 2, \ldots\}, \tag{1}$$

e média e variância condicionais

$$E(Y_i \mid x_i) = \mu_i, \qquad \text{Var}(Y_i \mid x_i) = \mu_i. \tag{2}$$

A igualdade entre média e variância é a hipótese de equidispersão. Se a variância observada for consideravelmente superior, existe uma sobredispersão.

C2. Função de ligação logarítmica

Definimos o preditor linear $\eta_i = x_i^\top \beta = \log(\mu_i)$, de modo que

$$\mu_i = \exp(x_i^\top \beta) > 0, \tag{3}$$

pois $\exp(z) > 0 \, \forall z \in \mathbb{R}$. Essa ligação garante que a média seja positiva e possui uma interpretação direta dos coeficientes.

C3. Interpretação dos coeficientes

Para uma covariável dicotômica (como as variáveis *dummy* que serão usadas) com as demais variáveis fixas:

$$\frac{\mu(x_j = 1, x_{-j})}{\mu(x_j = 0, x_{-j})} = \frac{\exp(\beta_0 + \cdots + \beta_j + \cdots + \beta_p x_p)}{\exp(\beta_0 + \cdots + 0 + \cdots + \beta_p x_p)} = \exp(\beta_j), \tag{4}$$

isto é, $\exp(\beta_j)$ é a razão das médias.

A quantidade $100\{\exp(\beta_j) - 1\}\%$ é a variação percentual no número médio de dias de ausência (`Days`) ao passar de $x_j = 0$ para $x_j = 1$.

C4. Estruturas média–variância

Os três modelos que serão considerados:

$$\text{Poisson:} \quad \text{Var}(Y_i \mid x_i) = \mu_i, \tag{5}$$

$$\text{quase-Poisson:} \quad \text{Var}(Y_i \mid x_i) = \phi \, \mu_i, \tag{6}$$

$$\text{binomial negativo:} \quad \text{Var}(Y_i \mid x_i) = \mu_i + \alpha \, \mu_i^2. \tag{7}$$

O parâmetro $\phi > 0$ da quase-Poisson mantém a relação linear entre média e variância, mas permite modelar uma não-equidispersão. Já $\alpha \geq 0$, na binomial negativo, é um fator multiplicativo no quadrado da média. Na prática, é o único dos 3 modelos em que a variâncai é uma função de μ_i^2 e não de μ_i.

C5. Quase-Poisson e AIC

O modelo quase-Poisson especifica apenas os dois primeiros momentos condicionais, $E(Y_i \mid x_i) = \mu_i$ e $\text{Var}(Y_i \mid x_i) = \phi\mu_i$, portanto não é uma distribuição completa. Como o AIC exige o máximo da log-verossimilhança e o modelo fornece apenas uma função de quase-log-verossimilhança, o AIC usual não é definido. Para comparar modelos é possível usar o QAIC ou a análises baseadas em *deviance*.

Parte D - Estrutura Sistemática e Inferência

Consideraram-se as estruturas

$$
\begin{aligned}
M_0 &: \eta_i = \beta_0, \\
M_1 &: \eta_i = \beta_0 + \mathrm{Eth}_i + \mathrm{Sex}_i + \mathrm{Age}_i + \mathrm{Lrn}_i, \\
M_2 &: M_1 + \mathrm{Eth}_i{:}\mathrm{Sex}_i, \\
M_3 &: M_1 + \mathrm{Age}_i{:}\mathrm{Lrn}_i, \\
M_4 &: M_1 + \mathrm{Eth}_i{:}\mathrm{Age}_i + \mathrm{Age}_i{:}\mathrm{Lrn}_i,
\end{aligned}
$$

D1. Ajuste do modelo M_1 (Poisson)

A Tabela 3 apresenta o ajuste do modelo aditivo M_1 com a componente aleatória sendo Poisson.

Tabela 3: Modelo M_1 (Poisson, ligação logarítmica): coeficientes, erros-padrão, p-valores e razões de médias com IC de 95%.

Termo	$\hat{\beta}$	EP	p-valor	$\exp(\hat{\beta})$	IC 95% inf.	IC 95% sup.
Intercepto	1,8479	0,0663	$4{,}9 \times 10^{-171}$	6,346	5,573	7,227
`Eth` A	0,5336	0,0419	$3{,}5 \times 10^{-37}$	1,705	1,571	1,851
`Sex` M	0,1616	0,0425	$1{,}5 \times 10^{-4}$	1,175	1,081	1,278
`Age` $F0$	0,3339	0,0701	$1{,}9 \times 10^{-6}$	1,396	1,217	1,602
`Age` $F2$	0,5917	0,0568	$1{,}9 \times 10^{-25}$	1,807	1,617	2,020
`Age` $F3$	0,7616	0,0703	$2{,}4 \times 10^{-27}$	2,142	1,866	2,458
`Lrn` SL	0,3489	0,0520	$2{,}0 \times 10^{-11}$	1,418	1,280	1,570

D2. Interpretação dos contrastes

Todos os coeficientes são significativos ao nível usual. Mantidas as demais covariáveis fixas, interpretamos:

- Intercepto: O valor $\exp(1{,}8479) = 6{,}346$ representa a média estimada da variável `Days` na categoria de referência adotada (N, F, $F1$, AL).
- Etnia (`Eth`): Estudantes aborígenes têm, em média, 70,5% a mais de ausências em relação aos não aborígenes ($\exp(\hat{\beta}) = 1{,}705$).
- Situação de Aprendizagem (`Lrn`): Estudantes com aprendizagem lenta têm, em média, 41,8% a mais de ausências em relação ao grupo de referência ($\exp(\hat{\beta}) = 1{,}418$).
- Idade (`Age`): Estudantes no nível $F3$ apresentam, em média, 114,2% a mais de ausências ($\exp(\hat{\beta}) = 2{,}142$) em comparação ao grupo de referência ($F1$).

D3. Significância global dos fatores

A Tabela 4 indica o resultado do teste de razão de verossimilhanças de cada fator em relação ao modelo sem ele.

Tabela 4: Análise de *deviance* do modelo M_1

Fator	Queda de *deviance*	GL	p-valor
`Eth`	166,84	1	$3{,}6 \times 10^{-38}$
`Sex`	14,40	1	$1{,}5 \times 10^{-4}$
`Age`	168,32	3	$2{,}9 \times 10^{-36}$
`Lrn`	45,80	1	$1{,}3 \times 10^{-11}$

Todos os fatores são globalmente significativos, com destaque para `Age` e `Eth`.

Uma variável com várias categorias tem sua contribuição global dividia entre elas. Assim, é possível que categorias individuais não sejam significativas e a variável, como um todo, seja relevante. Por isso, a decisão de manter ou retirar um fator deve se basear em testes globais, e não apenas nos p-valores individuais.

D4. Comparação entre M_0 e M_4

A Tabela 5 mostra a comparação das cinco estruturas sob a distribuição de Poisson, e a Tabela 6 apresenta os testes de razão de verossimilhanças entre modelos aninhados.

Tabela 5: Comparação das estruturas M_0–M_4 (Poisson).

Modelo	Termos	Deviance	GL resid.	AIC	BIC
M_0	intercepto	2073,53	145	2664,01	2666,99
M_1	`Eth`+`Sex`+`Age`+`Lrn`	1696,71	139	2299,18	2320,07
M_2	M_1+`Eth:Sex`	1674,87	138	2279,35	2303,22
M_3	M_1+`Age:Lrn`	1687,94	137	2294,41	2321,27
M_4	M_1+`Eth:Age`+`Age:Lrn`	1535,22	134	2147,69	2183,50

Tabela 6: Testes de razão de verossimilhanças entre modelos aninhados.

Comparação	Estatística	GL	p-valor
M_0 vs M_1	376,83	6	$2{,}7 \times 10^{-78}$
M_1 vs M_2	21,83	1	$3{,}0 \times 10^{-6}$
M_1 vs M_3	8,77	2	$1{,}2 \times 10^{-2}$
M_3 vs M_4	152,72	3	$6{,}8 \times 10^{-33}$

As comparações entre os modelos indicam que os efeitos principais são fundamentais (M_0 vs. M_1), e ambas as interações testadas trazem ganhos significativos ($p < 0{,}05$). O modelo M_4, por apresentar os menores valores de *deviance* (1535,22), AIC (2147,69) e BIC (2183,50), se destaca.

No entanto, duas limitações importantes devem ser consideradas sobre M_4:

- A ausência de observações para a combinação Age = $F3$ com Lrn = SL gera parâmetros não identificáveis.
- A hipótese de equidispersão adotada é violada pois a razão de dispersão $\frac{1696{,}71}{139} \approx 12{,}21$ é muito superior a 1. É nescessário utilizar outros modelos para evitar a inflação na significância dos testes estatísticos.

  A princípio, por uma questão de parcimônia será considerado o modelo M_1.

D5. Predição para perfis de estudantes

Para ilustrar o impacto das covariáveis, estimamos o número médio de dias de ausência para quatro perfis distintos de estudantes. Os resultados são apresentados na Tabela 7.

Tabela 7: Estimativas de dias de ausência para quatro perfis de estudantes.

Perfil	Eth	Sex	Age	Lrn	Média Prevista ($\hat{\mu}$)	IC 95%
Perfil 1	N	F	F0	AL	8,86	[7,50; 10,47]
Perfil 2	A	F	F0	AL	15,11	[12,98; 17,59]
Perfil 3	N	M	F3	SL	23,39	[18,45; 29,66]
Perfil 4	A	M	F3	SL	39,88	[31,50; 50,49]

A razão de médias entre o Perfil 2 e o Perfil 1, reflete o efeito de etnia ($\approx$ 1,70, como apresentado anteriormente). O Perfil 4, que combina todas as categorias associadas as maiores ausências, apresenta uma estimativa média de quase 40 dias, refletindo um efeito cumulativo entre as covariáveis.

D6. Associação versus Causalidade

Os resultados indicam apenas associação, não causalidade, pois os dados são observacionais, existem outras variáveis não observadas que podem influenciar na resposta. Os coeficientes refletem as diferenças médias entre as categorias, não o impacto direto de uma intervenção nessas variáveis, justamente por existirem diversos outros fatores não medidos associados a elas.

Parte E — Dispersão e Escolha da Distribuição

E1. Dispersão de Pearson

A estimativa da dispersão de Pearson para o modelo de Poisson ajustado é dada por:

$$\hat{\phi}_P = \frac{1}{n-p} \sum_{i=1}^{n} \frac{(y_i - \hat{\mu}_i)^2}{\hat{\mu}_i} \tag{8}$$

onde $n = 146$ e p é o número de parâmetros do modelo. No modelo de Poisson, espera-se que $\hat{\phi}_P \approx 1$ (equidispersão). Valores $\hat{\phi}_P > 1$ indicam sobredispersã, enquanto $\hat{\phi}_P < 1$ indicam subdispersão.

Para os dados da base `quine`, observamos $\hat{\phi}_P \approx 13{,}17$, indicando uma grande sobredispersão e invalidando a variabilidade ajustada do modelo de Poisson, que estará artificialmente baixo

E2. Razão do Desvio Residual

Como discutido anteriormente, a razão de dispersão ($1696{,}71/139 \approx 12{,}2$) também aponta para uma forte sobredispersão. Contudo, nenhuma destas estatísticas deve ser usada isoladamente como prova definitiva, pois valores elevados podem surgir também por uma má especificação da estrutura sistemática (ex: omissão de covariáveis importantes, poucas interações relevantes, ou uma predição incorreta).

E3. Proporção de Zeros Prevista e Observada

A proporção observada de zeros na base é $\hat{p}_0 = 9/146 \approx 6{,}16\%$. A proporção média de zeros prevista pelo modelo de Poisson é calculada pela média das probabilidades individuais preditas:

$$\hat{p}_{0,P} = \frac{1}{n} \sum_{i=1}^{n} e^{-\hat{\mu}_i} \approx 0.000097 \tag{9}$$

Existe uma evidência de um excesso de zeros na amostra em relação ao que o modelo de Poisson suporta, este execesso pode derivar da sobredisperção observada

E4. Ajuste Quase-Poisson e Binomial Negativo

Ajustando o mesmo preditor sob as famílias quase-Poisson e binomial negativa, observamos os resultados apresentados na Tabela 8:

Tabela 8: Comparação de Coeficientes e Erros-Padrão entre os Modelos

	Poisson		**Quase-Poisson**		**Binomial Negativa**	
Variável	**Beta**	**EP**	**Beta**	**EP**	**Beta**	**EP**
Intercept	1.847875	0.066283	1.847875	0.240517	1.878010	0.235565
Eth[T.A]	0.533604	0.041883	0.533604	0.151978	0.570051	0.171634
Sex[T.M]	0.161597	0.042535	0.161597	0.154341	0.080385	0.178979
Age[T.F0]	0.333901	0.070093	0.333901	0.254342	0.449765	0.268027
Age[T.F2]	0.591730	0.056762	0.591730	0.205969	0.536005	0.228140
Age[T.F3]	0.761595	0.070291	0.761595	0.255060	0.805675	0.274724
Lrn[T.SL]	0.348943	0.052043	0.348943	0.188844	0.290167	0.208473

As estimativas pontuais dos coeficientes são exatamente iguais nos modelos Poisson e Quase-Poisson. No entanto, os erros-padrão no modelo Quase-Poisson são consideravelmente maiores, isso evidencia a forte sobredispersão dos dados, confirmando que o modelo de Poisson original estava subestimando a incerteza e gerando erros-padrão artificialmente baixos.

O modelo Binomial Negativo apresenta estimativas pontuais ligeiramente diferentes dos outros dois modelos, pois assume uma estrutura de variância quadrática em vez de linear. Assim como no Quase-Poisson, os erros-padrão da Binomial Negativa são substancialmente maiores que os do modelo de Poisson. Isso mostra que tanto a Quase-Poisson quanto a Binomial Negativa conseguem capturar a variabilidade dos dados melhor que a Poisson.

E5. Comparação e Escolha Provisória

Ao comparar o modelo Poisson original e o Binomial Negativo, o BN apresenta AIC e BIC consideravelmente menores (ΔAIC e $\Delta BIC \approx 1190$).

Para o modelo quase-Poisson, o AIC não é definido. Entretanto indo de acordo com o observado na análise exploratória, consideraremos o melhor modelo o Binomial Negativo por sua variância ter uma relação quadrática.

Parte F — Resíduos e Influência

F1. Resíduos de Pearson e Deviance

Para avaliar a adequação dos ajustes comparamos os resíduos de Pearson e de desvio (*deviance*) padronizados para os modelos de Poisson e Binomial Negativo. As Figuras 3 e 4 apresentam a dispersão desses resíduos contra os valores preditos, contra o índice de observações e separados pelo principal fator de idade (`Age`).

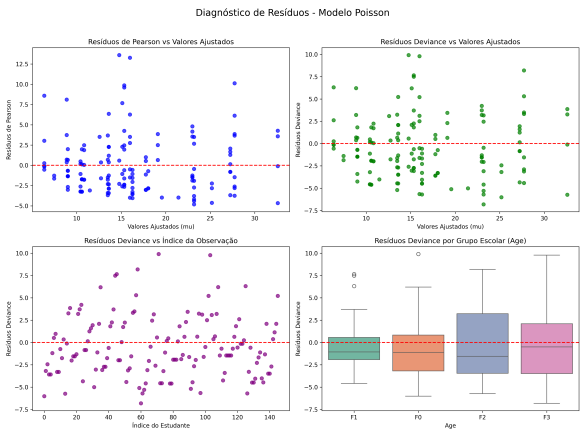


Figura 3: Diagnóstico de resíduos para o modelo de Poisson.

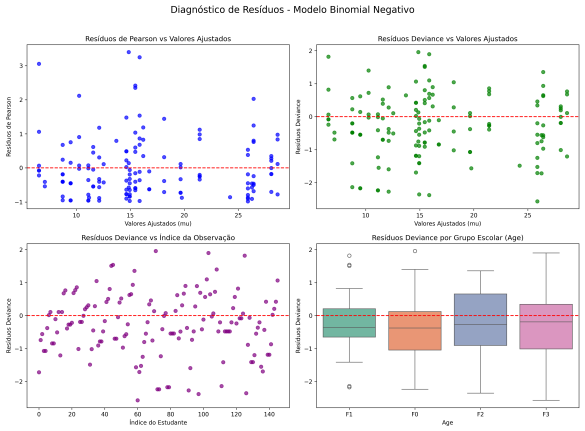


Figura 4: Diagnóstico de resíduos para o modelo Binomial Negativo.

- Na Figura 3, os gráficos de resíduos atingem valores extremos, superando a marca de 10 ou caindo abaixo de -5. Isso mostra que a variância cresce muito mais rápido que a média predita de fato.
- Na Figura 4, a escala dos resíduos é bem menor, indicando valores mais próximos de zero.
- Os gráficos de resíduos de *deviance* contra o índice da observação tem um comportamento aleatório, reforçando que não existe nenhuma tendência e nem relação temporal.

F2. Q-Q Plot com Envelope Simulado

Como a variável resposta (`Days`) discreta e assimétrica, os resíduos de modelos para dados de contagem não seguem uma distribuição perfeitamente Normal. Comparar esses resíduos discretos diretamente com uma reta contínua teórica em um gráfico Q-Q não é a melhor opção. O envelope simulado *Half-Normal* resolve esse problema, além de atender o suporte esperado.

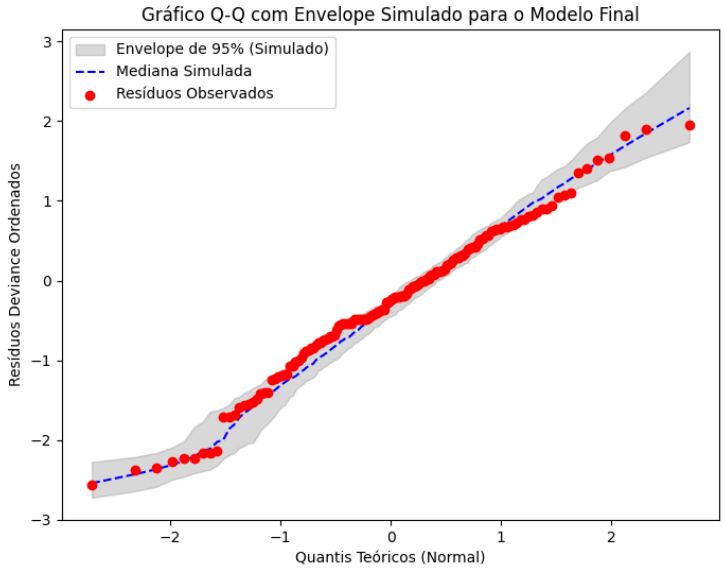


Figura 5: Gráfico Q-Q com envelope simulado de 95% para o modelo Binomial Negativo considerando M_1.

A Figura 5 revela um comportamento ideal, os resíduos observados estão contidos dentro dos limites do envelope de confiança simulado. Esse resultado fortalece a hipótese de que a Binomial Negativa é adequada para os dados.

F3. Diagnóstico de Observações Problemáticas

- Ponto discrepante (*Outlier*): É uma observação cujo valor observado da variável resposta (y_i) se afasta consideravelmente do valor predito pelo modelo.
- Ponto de alta alavancagem (*Leverage*): Uma observação que possui um padrão atípico ou extremo no espaço das variáveis explicativas (x_i). Esse ponto tem grande potencial de alterar o ajuste.
- Ponto influente: É a observação que, ao ser removida da base de dados, causa uma alteração substancial e significativa nas estimativas dos coeficientes ($\hat{\beta}$) do modelo. A medida mais comum para quantificar essa influência global é a Distância de Cook (D_i).

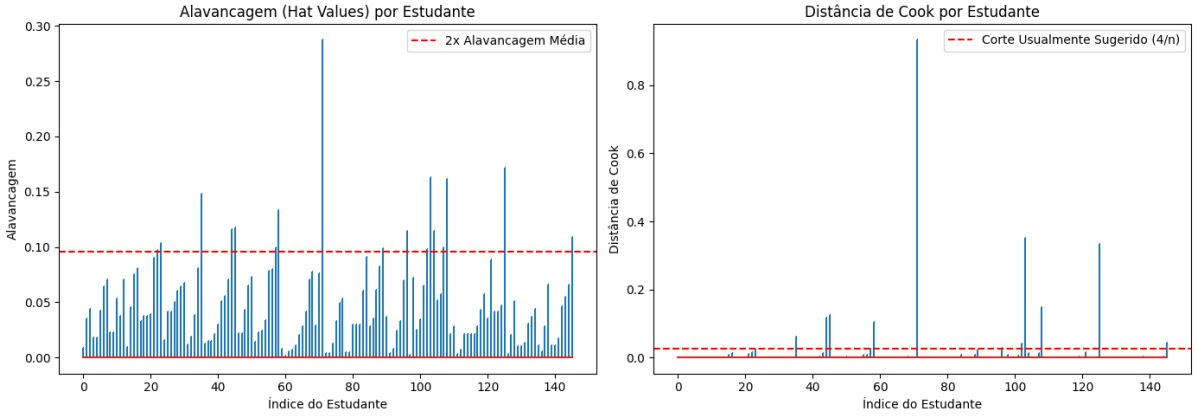


Figura 6: Gráficos de Alavancagem e Distância de Cook para identificação de pontos problemáticos.

A partir da Figura 6 concluimos:

- Diversas observações ultrapassam a linha de referência de duas vezes a alavancagem média, destacando um indivíduo com uma alavancagem próxima de 0,30.
- A Distância de Cook revela o impacto prático dessa alavancagem nas estimativas. O mesmo estudante próximo ao índice 70 exibe um pico na Distância de Cook muito superior à linha de corte de referência ($4/n$).

Com base nisso, dizemos que esse indivíduo em destaque é um ponto influente.

F4. Investigação de Estudantes Específicos

Com base nas métricas de diagnóstico, selecionamos os cinco estudantes mais influentes.

Tabela 9: Estudantes selecionados para investigação detalhada (BN em M_1).

Índ.	Days	Eth	Sex	Age	Lrn	Val. Ajust.	Resíduo	Alavanca.	D. Cook
71	67	N	M	F0	SL	14,85	1,96	0,287	0,934
103	69	N	M	F3	AL	15,86	1,90	0,163	0,352
125	28	N	F	F1	AL	6,54	1,82	0,172	0,333
108	33	N	F	F0	AL	10,26	1,40	0,162	0,147
45	54	A	F	F1	SL	15,46	1,54	0,118	0,127

O estudante 71 é o ponto mais influente do modelo, puxando fortemente o ajuste devido à sua combinação de alta alavancagem e grande discrepância entre o valor ajustado ($\approx 14,85$) e o real (67 dias). O estudante 103 também apresenta um número muito alto de faltas (69 dias)

No contexto desta base de dados, isso não significa que a observação está errada, ela pode ser explicada por diversos fatores, como saúde, viagens e condições climáticas, por exemplo.

F5. Análise de Sensibilidade

Tabela 10: Análise de Sensibilidade: Modelo Completo vs. Sem Influentes (BN em M_1)

	Modelo Completo			Sem Influentes		
Variável	**Beta**	**SE**	**Exp(Beta)**	**Beta**	**SE**	**Exp(Beta)**
Intercept	1,878	0,236	6,540	1,714	0,246	5,548
Eth[T.A]	0,570	0,172	1,768	0,699	0,176	2,011
Sex[T.M]	0,080	0,179	1,084	0,044	0,183	1,045
Age[T.F0]	0,450	0,268	1,568	0,324	0,280	1,383
Age[T.F2]	0,536	0,228	1,709	0,672	0,231	1,958
Age[T.F3]	0,806	0,275	2,238	0,826	0,282	2,285
Lrn[T.SL]	0,290	0,208	1,337	0,246	0,215	1,279

Conclusões com base na Tabela 10:

- A remoção dos pontos influentes altera levemente a alguns coeficientes, como o efeito para aborígenes (`Eth[T.A]`), cuja razão de médias sobe de 1,768 para 2,011.
- Os erros-padrão se mantiveram estáveis entre os dois cenários, indicando que a incerteza do modelo não é ditada por esses poucos pontos.
- O impacto dos casos influentes existe, mas não altera conclusões, então não há justificativa para a exclusão dessas observações.

Parte G — Validação Cruzada e Conclusão

G1. Construção dos Grupos Estratificados

Para a validação cruzada, a partição em $K = 10$ folds foi realizadoa de forma estratificada. Devido ao baixo tamanho da amostra, a estratificação foi construída combinando os níveis de origem étnica (`Eth`) e situação de aprendizagem (`Lrn`). Essa abordagem lida com o desbalanceamento das categorias garante a representatividade.

G2. Avaliação de Perda e Erro Fora da Amostra

A avaliação preditiva fora da amostra gerou as seguintes métricas médias:

Tabela 11: Avaliação preditiva fora da amostra (Validação Cruzada).

Modelo	$\mathbf{Dev}_{CV}$	$\mathbf{MAE}_{CV}$	$\mathbf{RMSE}_{CV}$
Poisson (M_1)	193,41	11,68	15,16
Binomial Negativo (M_1)	194,34	11,76	15,31

A correlação simples não deve ser utilizada como critério principal porque mensura apenas a associação linear. Métricas como as apresentadas na Tabela 11 são mais adequadas por refletirem a verdadeira magnitude do erro preditivo da distribuição sob análise.

Vale ressaltar que as estimativas geradas pela quase-poisson são iguais as gerads pela poisson.

G3. Comparação de Critérios e Conclusão Final

A validação cruzada revelou um desempenho preditivo praticamente idêntico entre os dois modelos, havendo até uma vantagem mínima para o modelo de Poisson em todas 3 as métricas observadas.

A validação cruzada foca na previsão pontual da média ($\hat{\mu}$), que é numericamente semelhante em ambos os modelos. Contudo, a validação preditiva ignora a estrutura da variância. Como demonstrado anteriormente pelos critérios de informação e pelos diagnósticos de sobredispersão, o modelo de Poisson falha ao quantificar a incerteza dos dados.

Portanto, a ordem da validação cruzada não altera a decisão inicial de que o modelo Binomial Negativo deve ser mantido como a melhor escolha.

Conclusão

A análise indica que a estrutura sistemática de efeitos principais (M_1: `Days` $\sim$ `Eth + Sex + Age + Lrn`) combinada à distribuição Binomial Negativa oferece o melhor equilíbrio entre interpretação, adequação, estabilidade, parcimônia e capacidade preditiva.

O modelo de Poisson falha ao assumir equidispersão. A quase-poisson e a Binomial Negativa solucionam esse problema, entretanto pelo bom comportamento dos resíduos e pelo alinhamento no gráfico Q-Q com envelope simulado, além de ir de acordo com a hipótese inicial de uma relação quadrática com a média, elencamos a Binomial Negativa como superior. A análise de sensibilidade provou que o modelo resiste a observações influentes.

Por utilizar dados observacionais, os parâmetros estimados refletem apenas associações estatísticas e não relações causais. As diferenças encontradas não representam o efeito isolado de uma categoria pois existem diversos outros fatores influentes.

As referências se encontram no arquivo do trabalho dentro do repositório.